# RecDev: reconhecimento facial com deep learning e redução de dimensionalidade por PCA/SVD

**Gustavo Curty e Gabriel Woyames**

Instituto Politécnico — IPRJ
Universidade do Estado do Rio de Janeiro — UERJ

*Análise Linear Numérica — UERJ/IPRJ — 2026*

# Problema e pergunta experimental

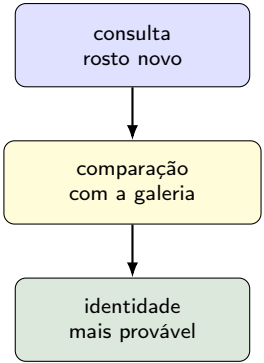
**Identificação fechada**

Dada uma **consulta**, o sistema escolhe a pessoa mais semelhante entre as identidades da **galeria**. A rede não é treinada do zero e desconhecidos não são avaliados.

**Pergunta do RecDev**

Quanto podemos reduzir os *embeddings* faciais preservando a capacidade de identificação?

- **Embedding**: vetor numérico que representa a face.
- Rede congelada gera 512 valores; PCA/SVD reduz antes da comparação.



# Dados FEI: identidade, fotografia-base e variantes

**Foto-base A**



limpa (captura original)

**Foto-base B e quatro condições**



limpa



escura



ruído



ruído + escura

## Três conceitos

**Identidade**: pessoa.
**Foto-base**: captura original.
**Variante**: transformação da captura.

## Bases FEI em foco

| Base | Identidades | Imagens |
|---|---|---|
| `medium` | 50 | 350 |
| `hard` | 50 | 700 |

## Cuidado experimental

As quatro condições mostradas são **variantes da mesma captura**; não são quatro fotografias independentes. Os resultados discutidos a seguir usam as partições de `medium`, `hard` e Facebook Faces.

# Facebook Faces: dois recortes, mesmo protocolo

## Quatro bases adicionais

Cada base contém cinco identidades. `inner`: face mais fechada; `outer`: mais contexto.

| Base | Imagens | Validação | Teste |
|---|---|---|---|
| fb1 (inner/outer) | 45 | 5 | 30 |
| fb2 (inner/outer) | 50 | 5 | 35 |

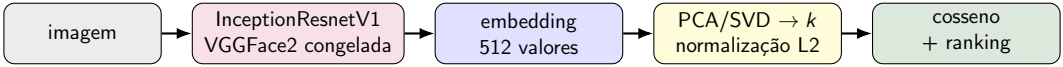
## Partição por foto

- Galeria : fotos 1 e 2 (10 imagens).
- Validação : foto 3 (5 imagens).
- Teste : fotos 4–9 (fb1) ou 4–10 (fb2).

## Leitura correta

Cada recorte ajusta seu próprio PCA, escolhe $k$ na validação e só então mede o teste.

# Visão geral: pipeline único do RecDev




**Ajuste permitido**

Rede congelada; apenas o PCA é ajustado, exclusivamente na galeria.

**Decisão**

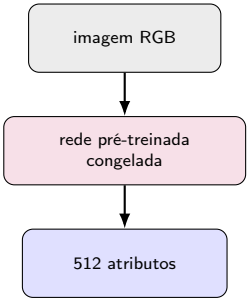
A identidade é a que possui a maior similaridade de cosseno no espaço reduzido.

# Da imagem ao embedding: a rede não é reajustada

- InceptionResnetV1 pré-treinada em **VGGFace2**: entrada padronizada em $160 \times 160$.
- Inferência em lotes: cada saída tem 512 números em `float32`.
- `eval()` e `requires_grad_(False)` congelam os pesos; PCA local **não** é *fine-tuning*.

**Embedding**

$$\text{imagem} \longmapsto e \in \mathbb{R}^{512}$$



# PCA/SVD sobre a matriz de embeddings

Para $n$ imagens da galeria, cada linha de $E \in \mathbb{R}^{n \times 512}$ é um embedding normalizado.

## 1. Centralizar

$$E_c = E - 1\mu^T$$

$\mu$: média da galeria. Remove a origem comum antes de estudar as direções de variação.

## 2. Decompor

$$E_c = U\Sigma V^T$$

Valores em $\Sigma$ medem a variação em cada direção de $V$; os maiores vêm primeiro.

## 3. Projetar

$$Z = E_c V_k$$

$V_k$: primeiras $k$ direções. Cada rosto passa de 512 coordenadas para $k$.

## O que se mede

Variância retida: fração da energia dos valores singulares preservada. Reconstrução aproximada: $\widehat{E} = ZV_k^T + 1\mu^T$.

## Depois da projeção

Para embeddings, normalizamos $z/\|z\|_2$ e usamos $\cos(z, q) = z^T q$; cosseno mede ângulo, não magnitude.

# PCA no código: posto numérico evita uma direção instável

```
self.mean_ = x.mean(axis=0)
_, singular, vt = np.linalg.svd(x - self.mean_,
                                full_matrices=False)
self.tolerance_ = float(np.finfo(x.dtype).eps *
                        max(x.shape) * singular[0])
self.rank_ = min(int(np.count_nonzero(
    singular > self.tolerance_)), len(x) - 1)
self.basis_ = vt[:self.rank_].copy()
```

Trecho real de `src/recdev/pca.py`, linhas 18-27 (condensado).

## Limite matemático

Após centralizar, $\text{posto}(E_c) \leq \min(n-1, d)$. Com 5 imagens: no máximo **4** componentes não nulas.

## Correção da versão anterior

Antes, $k = 5$ levava *whitening* a uma componente quase nula. A tolerância agora a descarta; *whitening* fica desligado.

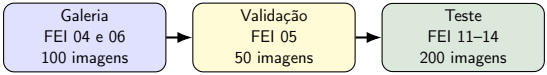
# Consulta: mesma projeção, normalização e ranking

```
projected_gallery = l2_normalize(pca.transform(
    gallery, k))
projected_queries = l2_normalize(pca.transform(
    queries, k))
score_matrix = np.clip(projected_queries @
                       projected_gallery.T, -1.0,
     1.0)
predicted, scores = _nearest(projected_queries,
                             projected_gallery,
    gallery_labels)
```

Trecho real de `src/recdev/identify.py`, linhas 131-150 (condensado).

1. A consulta vira embedding e é normalizada.
2. Usa $z = (e - \mu)V_k$ da **galeria salva**; não ajusta PCA novamente.
3. Normaliza $z$ para cosseno estável: $z / \max(\|z\|_2, \epsilon)$.
4. O produto $qG^T$ dá scores para a galeria; o ranking conserva a melhor amostra por identidade.

# Protocolo: separar escolha de $k$ e teste final




```
1 gallery=[r for r in records if r.source_photo in
      ("04", "06")]
2 validation=[r for r in records if r.source_photo
      == "05"]
3 test=[r for r in records if r.source_photo in ("
     11", "12", "13", "14")]
```

Trecho real de `src/recdev/data.py`, linhas 164-169 (condensado).

**Decisão experimental**

A grade $k \in \{8, 16, 32, 64\}$ é comparada **somente** na validação. Maior acurácia vence; empate favorece o menor $k$.

**Sem vazamento**

Depois de escolher $k$, o teste é usado uma vez. A validação não entra na galeria e o PCA não é reajustado. Em Facebook Faces, a mesma regra é aplicada com fotos 1–2 / 3 / restantes, separadamente para cada recorte.

# Execução integrada e relatório explicável

## Execução reproduzível

```
python -m recdev -all
```

## O comando faz

Gera relatórios das bases disponíveis, com acertos, acurácia, $k$ e erros. Nesta apresentação, destacamos `medium`, `hard` e Facebook Faces; os resultados são gravados em `artifacts/runs/{dataset}.json` e `summary.json`.

## Para que serve o detalhe por consulta?

No $k$ representativo, o JSON registra acertos, desempenho por condição/pose e cada erro, para podermos investigar exemplos concretos.

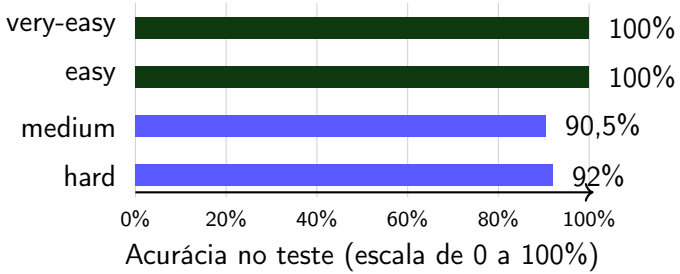
## Um erro fica rastreável

Para cada consulta incorreta: identidade verdadeira, identidade prevista, arquivo da galeria que venceu, score e condição/pose.

## Como interpretar

O relatório relaciona acerto/erro ao $k$, à variância retida, à margem entre os dois melhores scores e à pose. Ele descreve evidências; a pose sugere uma causa, mas não prova sozinha o motivo visual.

# Resultados FEI: very-easy, easy, medium e hard



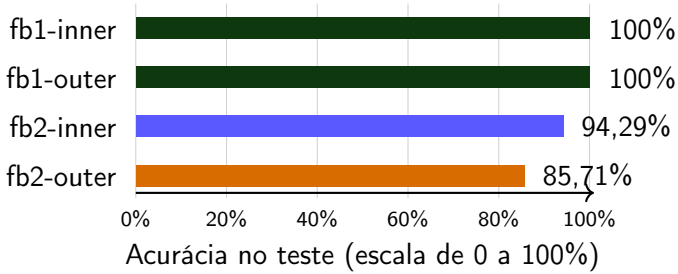

**Acertos e dimensão**

`very-easy`: 10/10, $k = 2$.
`easy`: 40/40, $k = 3$.
`medium`: 181/200, $k = 8$.
`hard`: 506/550, $k = 8$.

**Como ler**

`very-easy` e `easy` são resultados descritivos: $k$ não foi escolhido com validação independente. Para `medium` e `hard`, $k$ foi escolhido na validação.

# Facebook Faces: resultados por recorte




**Acertos e $k$**

fb1-inner: 30/30, $k = 4$.
fb1-outer: 30/30, $k = 3$.
fb2-inner: 33/35, $k = 3$.
fb2-outer: 30/35, $k = 2$.

**Maior queda**

`fb2-outer` teve cinco erros, todos entre as identidades 3 e 5; a margem top-1–top-2 média dos erros foi 0,004.

# Resumo geral: 810 acertos em 880 consultas

## Resultado ponderado

92,05%

810 / 880 consultas corretas

## As bases não são intercambiáveis

O percentual geral é ponderado pelo número de consultas de `medium`, `hard` e Facebook Faces. Cada base mantém seu próprio protocolo e dificuldade.

## Origem dos acertos

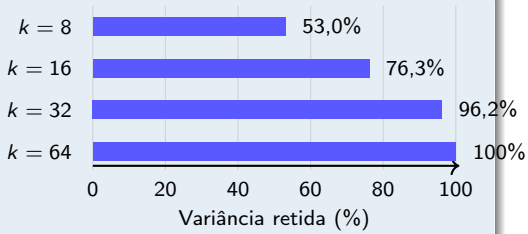
FEI (medium + hard): 687/750 (91,60%).
Facebook Faces: 123/130 (94,62%).

## Contagens não medem dificuldade

O `hard` tem 44 dos 70 erros em 550 consultas; o `medium`, 19 em 200; Facebook Faces, 7 em 130. As diferenças entre protocolos impedem comparar dificuldade só pela contagem.

# Escolha de $k$: validação antes do teste

## FEI: variância retida por dimensão




## Facebook Faces: $k$ escolhido

| Base | Melhor validação | $k$ | Teste |
|---|---|---|---|
| fb1-inner | 5/5 | 4 | 30/30 |
| fb1-outer | 5/5 | 3 | 30/30 |
| fb2-inner | 5/5 | 3 | 33/35 |
| fb2-outer | 5/5 | 2 | 30/35 |

## Todos empataram na validação

Todos os $k$ acertaram 50/50; pelo desempate, fica o menor: $k = 8$.

## Variância não seleciona sozinha

`fb2-outer`: $k = 2$ retém 52,8% da variância. Mais dimensões melhoram a reconstrução, mas a validação segue 5/5; por isso, $k$ é escolhido pela acurácia.

Variância mede reconstrução global, não separação entre identidades.

# Dois erros concretos: confusão próxima e erro por pose

## Medium: concorrentes muito próximos



consulta: pessoa 5



galeria vencedora: pessoa 22

Scores: prevista 0,930; verdadeira 0,904.
$\Delta = 0,026$; pose 14.

## Hard: mudança de pose mais severa



consulta: pessoa 8



galeria vencedora: pessoa 39

Scores: prevista 0,671; verdadeira $-0,615$.
$\Delta = 1,286$; pose 14.

## O que os exemplos sugerem

Pose 14: 16 erros em 50 consultas (68% de acerto); associação observada, não causalidade. Pares recorrentes: medium 5 $\rightarrow$ 22 (2 vezes) e hard 15 $\rightarrow$ 28 (3 vezes).

Nota: $\Delta$ compara o score previsto ao da identidade verdadeira; não é a margem entre 1º e 2º lugar.

# Facebook Faces: o recorte externo torna erros ambíguos

## Consulta 3, foto 9



consulta: pessoa 3



galeria vencedora: pessoa 5

Score previsto: 0,9990; melhor score da verdadeira: 0,9949;
$\Delta = 0,0040$.

## Consulta 5, foto 9



consulta: pessoa 5



galeria vencedora: pessoa 3

Score previsto: 0,9998; melhor score da verdadeira: 0,9958;
$\Delta = 0,0040$.

## Interpretação do resultado `fb2-outer`

Foram 30/35 acertos (85,71%). Os cinco erros ocorrem apenas entre as pessoas 3 e 5; a margem média top-1–top-2 dos erros é 0,004, contra 0,456 nos acertos. Scores altos não significam confiança quando o concorrente correto está praticamente empatado. O resultado sugere que o recorte externo preserva variação que dificulta a separação neste conjunto; não demonstra causalidade visual isoladamente.

# Conclusões: resultado, erros e limites

## Resultado agregado

Foram 810 acertos em 880 consultas (92,05%, média ponderada): FEI `medium` + `hard`, 687/750; Facebook Faces, 123/130.

## Como interpretar os erros?

O `hard` teve 44/550 erros (8,0%); o `medium`, 19/200 (9,5%); Facebook Faces, 7/130 (5,38%). Como os protocolos e recortes diferem, essas taxas não são uma comparação direta de dificuldade.

- $k$ varia de 2 a 8 e é decidido por validação; variância retida não mede diretamente a separação entre pessoas.
- FEI: pose 14 tem 16/50 falhas. `fb2-outer`: margem média dos erros 0,004.

## Fontes do trabalho

Documentação: `README.txt`; `docs/metodologia.md`. Código em `src/recdev/`.
Relatórios: `artifacts/runs/*.json` e `summary.json`.

## Referências essenciais

FEI Face Database; Thomaz e Giraldi (2010); *facenet-pytorch* / InceptionResnetV1 VGGFace2.